第三节笔记

RAG优势

解决 LLMs 在处理知识密集型任务时可能遇到的挑战, 如幻觉、知识过时和缺乏透明、可追溯的推理过程等。提供更准确的回答、降低推理成本、实现外部记忆。

RAG流程图

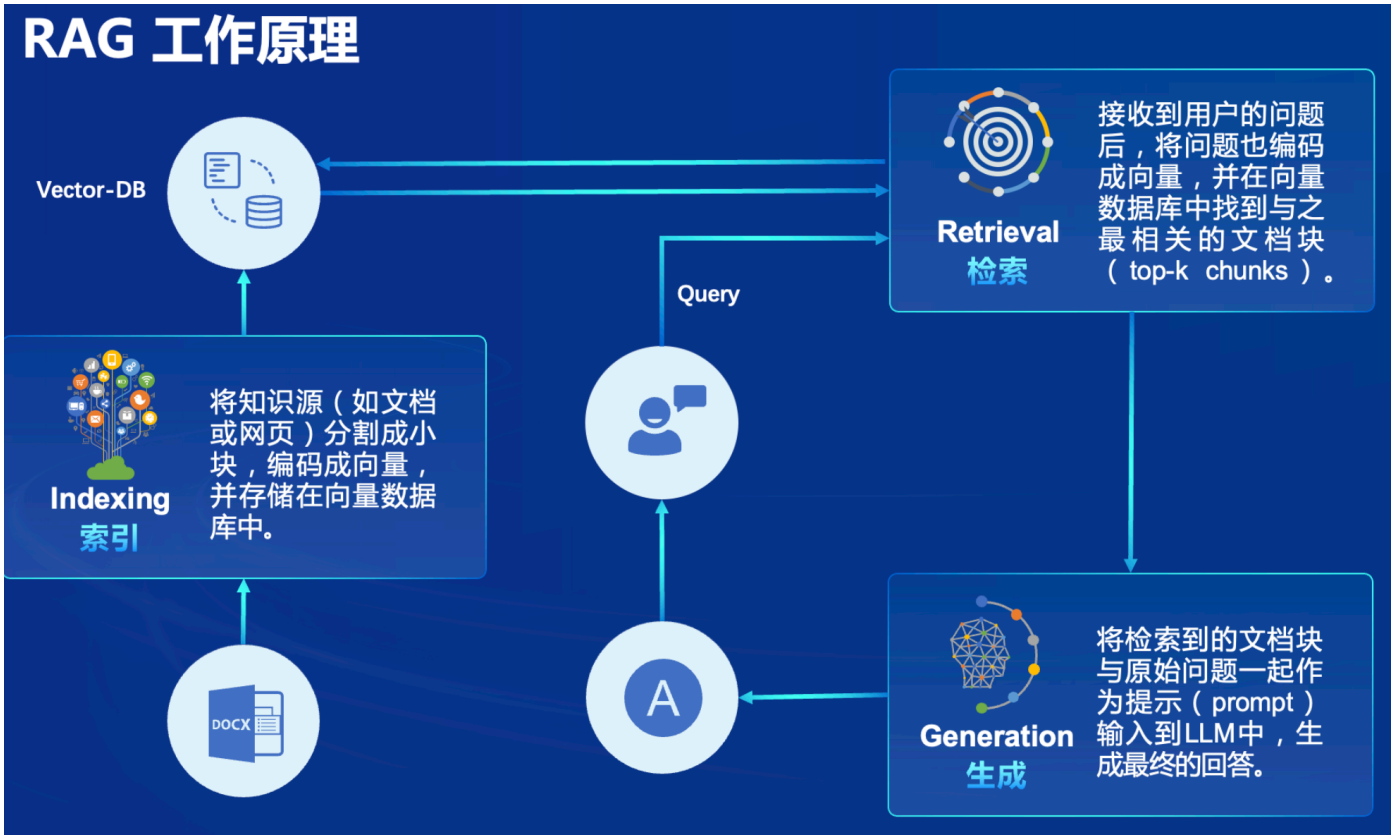

- 流程
    1. 输入文本转化为向量
    2. 在向量数据库中匹配相似文本
    3. 作为prompt在大模型中寻找答案

RAG部署与实践

1. 环境配置
   主要库的功能分析：

   protobuf==4.25.3 #负责与server端通信
   accelerate==0.28.0 #分布式部署

   bcembedding==0.1.3 # BCE embedding和reranker模型部署
   beautifulsoup4==4.8.2 #网页内容解析
   faiss-gpu==1.7.2 #向量数据库
   langchain==0.1.14 # RAG框架搭建

langchain可以实现如下图中的功能

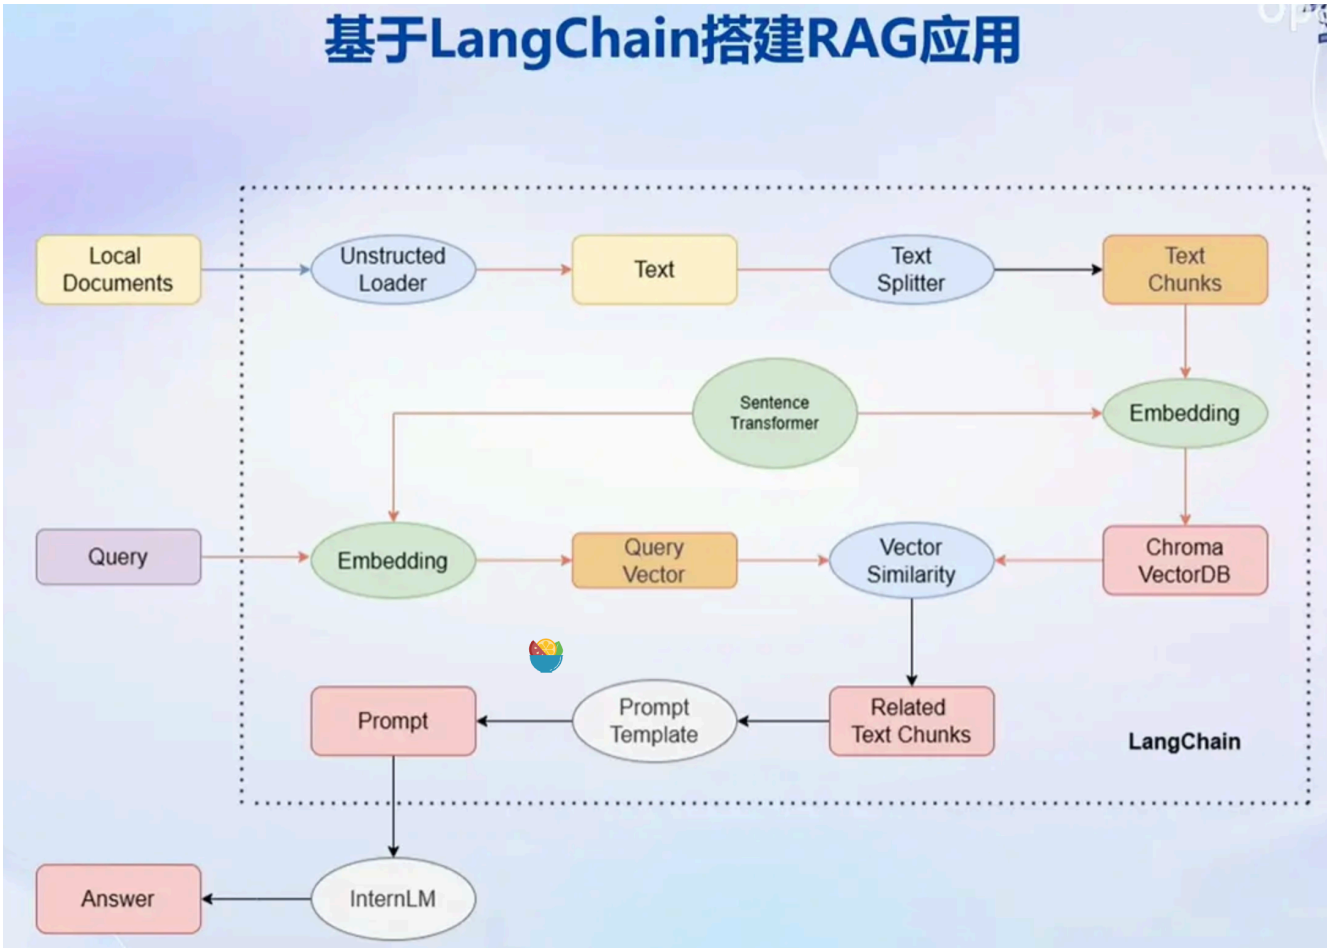

loguru==0.7.2 # 日志打印
pandas==2.2.1 # 构建知识库
pymupdf==1.24.1 python-docx==1.1.0 pytoml==0.1.21 readability-lxml==0.8.1 # 文档读取相关

2. 下载茴香豆的script文件及文档
3. 修改配置文件
   主要修改了三个模型的存储路径
4. 构建知识库
   提取知识库特征，创建向量数据库。数据库向量化的过程应用到了 **LangChain** 的相关模块，默认嵌入和重排序模型调用的网易 **BCE 双语模型** ，查看发现引用了这些文档作为知识库

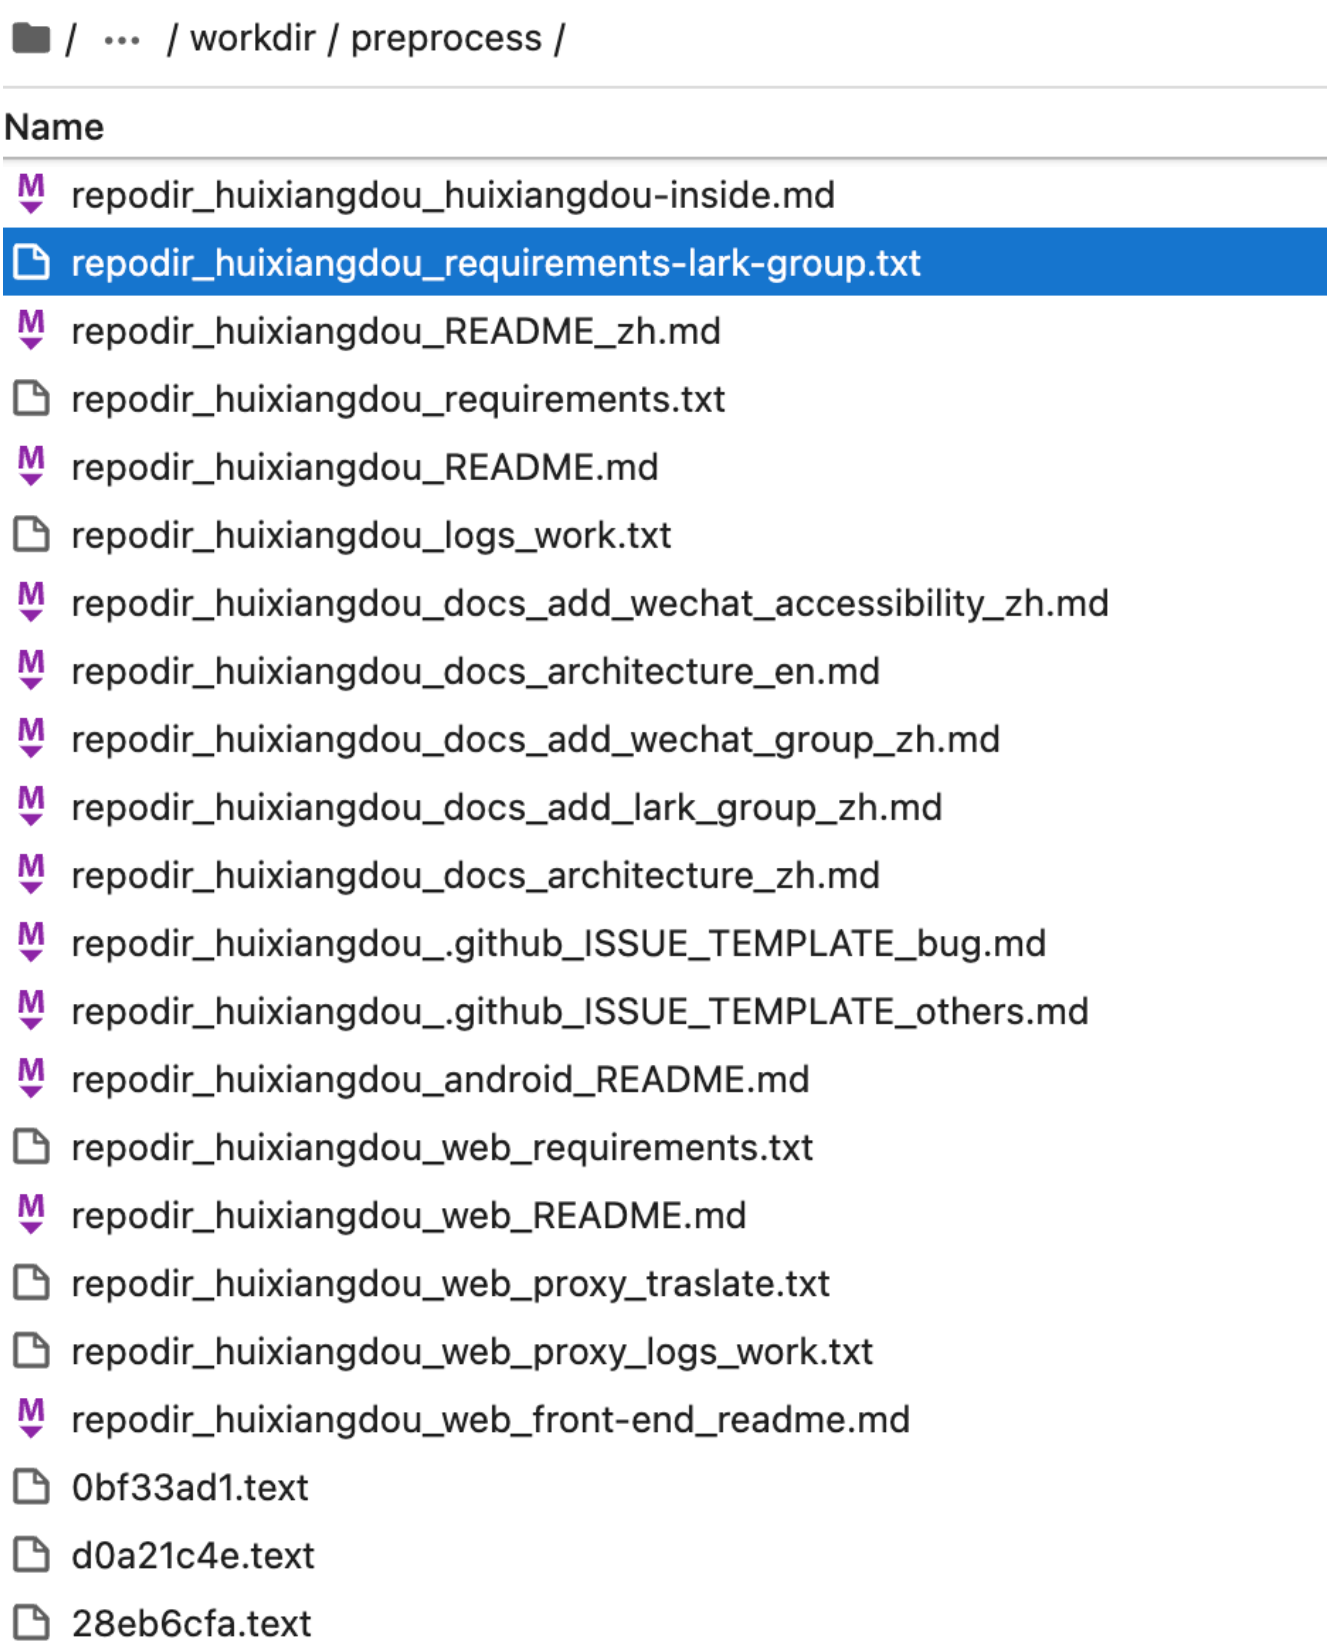

5. 构建good question和bad question

   这一步应该是为更好地判断query和知识库中文档的相关性，good question也是来源与上一步建好的知识库而来的，如果query与good question比较相似，即判断可以用rag来检索增强

6. 运行并测试