第四节笔记&作业

完成以下任务，并将实现过程记录截图：

- 配置 LMDeploy 运行环境
- 以命令行方式与 InternLM2-Chat-1.8B 模型对话

配置LMdeploy环境

1.1 创建开发机

因LMDeploy最新版本问题，注意选择镜像`Cuda12.2-conda`，以及`10% A100*1`

1.2 创建conda环境

InternStudio上提供了快速创建conda环境的方法。在命令行终端，创建名为`lmdeploy`的环境（全程大约10分钟）：

```
studio-conda -t lmdeploy -o pytorch-2.1.2
```

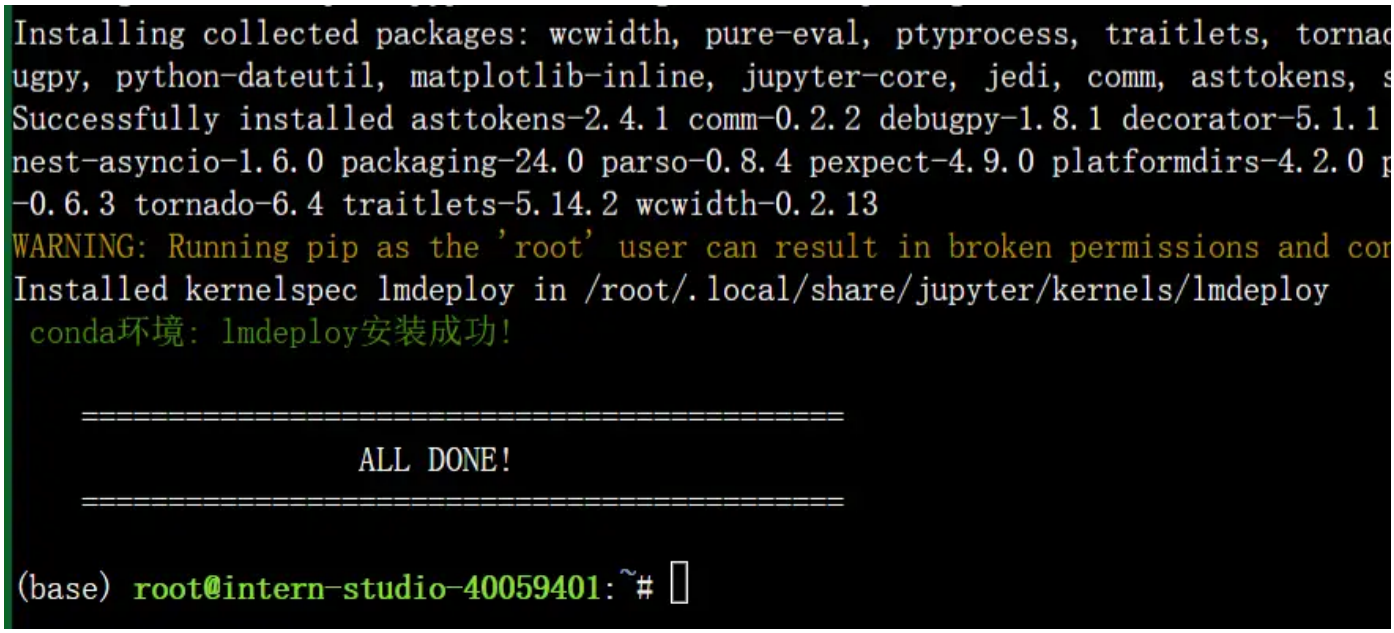

1.3 安装LMDeploy

激活刚刚创建的虚拟环境

```
conda activate lmdeploy
```

安装0.3.0版本的lmdeploy

```
pip install lmdeploy[all]==0.3.0
```

LMDeploy模型对话(chat)

2.1 Huggingface与TurboMind 简介

HuggingFace是一个针对深度学习模型和数据集的在线托管社区。如果你有数据集或者模型想对外分享，可以托管在HuggingFace。如果您想获取他人开源的的数据集或模型，也可以在HuggingFace中找到。托管的模型通常采用HuggingFace格式存储，简写为**HF格式**。

但是HuggingFace社区的服务器在国外，国内访问不太方便。国内可以使用阿里巴巴的MindScope社区，或者上海AI Lab搭建的OpenXLab社区，上面托管的模型也通常采用**HF(.safetensors)格式**。

TurboMind是LMDeploy团队开发的一款关于LLM推理的高效推理引擎，它的主要功能包括：LLaMa 结构模型的支持，continuous batch 推理模式和可扩展的 KV 缓存管理器。TurboMind推理引擎仅支持推理TurboMind格式的模型。因此，TurboMind在推理HF格式的模型时，会首先自动将HF格式模型转换为TurboMind格式的模型。

2.2 模型软链接

和前几节课类似，由开发机的共享目录**软链接**模型：

```
cd ~
ln -s /root/share/new_models/Shanghai_AI_Laboratory/internlm2-chat-1_8b /root/
```

2.3 使用Transformer库运行模型

在终端新建脚本`pipeline_transformer.py`

```
touch /root/pipeline_transformer.py
```

将以下内容复制粘贴进脚本`pipeline_transformer.py`

脚本大致内容为：加载`internlm2-chat-1_8b`，输入两个示例prompt，模型推理输出回答

```
import torch
from transformers import AutoTokenizer, AutoModelForCausalLM

tokenizer = AutoTokenizer.from_pretrained("/root/internlm2-chat-1_8b",
trust_remote_code=True)

# Set `torch_dtype=torch.float16` to load model in float16, otherwise it will be loaded as
float32 and cause OOM Error.
model = AutoModelForCausalLM.from_pretrained("/root/internlm2-chat-1_8b",
torch_dtype=torch.float16, trust_remote_code=True).cuda()
model = model.eval()

inp = "hello"
print("[INPUT]", inp)
response, history = model.chat(tokenizer, inp, history=[])
```

```
print("[OUTPUT]", response)

inp = "please provide three suggestions about time management"
print("[INPUT]", inp)
response, history = model.chat(tokenizer, inp, history=history)
print("[OUTPUT]", response)
```

然后运行该Python脚本

```
python /root/pipeline_transformer.py
```

全程用时大约 3 mins

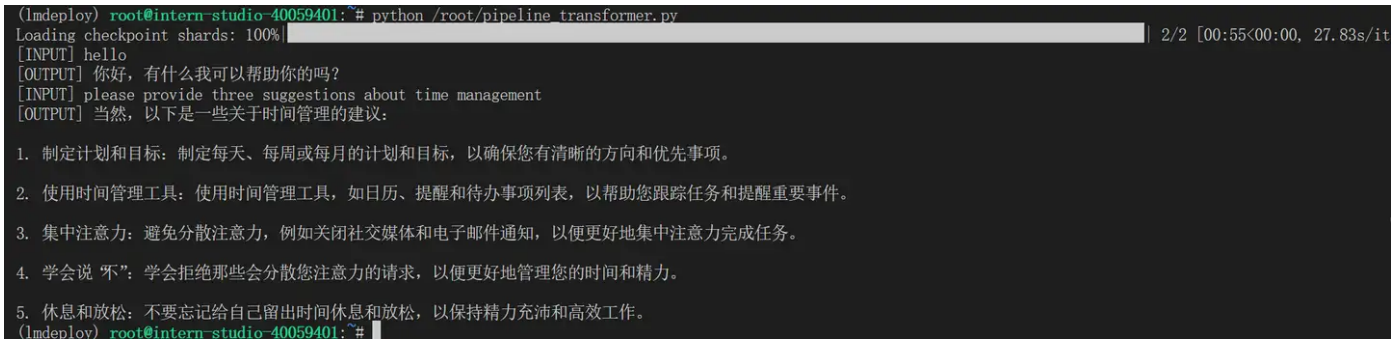

2.4 使用LMDeploy与模型对话

使用LMDeploy与模型进行对话（通用命令格式为`lmdeploy chat [模型路径]`）：

```
lmdeploy chat /root/internlm2-chat-1_8b
```

模型加载速度确实会比原生transformer快一些

```
double enter to end input >>> 给我一个关于健身频率的建议

<|im_start|>system
You are an AI assistant whose name is InternLM (书生·浦语).
- InternLM (书生·浦语) is a conversational language model that is developed by Shanghai AI
nd harmless.
- InternLM (书生·浦语) can understand and communicate fluently in the language chosen by t
<|im_end|>
<|im_start|>user
给我一个关于健身频率的建议<|im_end|>
<|im_start|>assistant
 2024-04-16 20:13:34,923 - lmdeploy - WARNING - kwargs ignore_eos is deprecated for infere
2024-04-16 20:13:34,923 - lmdeploy - WARNING - kwargs random_seed is deprecated for infere
当制定健身计划时，建议综合考虑个人健康状况、目标、时间和能力等因素。以下是一些可供参考的建

1. **定期评估进展**：
   - 定期记录体重、体脂百分比、肌肉质量等指标，并与之前的数据进行比较，评估健身效果。
   - 考虑进行定期体态检查，确保姿势正确且动作流畅。

2. **目标设定明确**：
   - 设定具体、可衡量和有时限的目标，例如增加肌肉量或减轻体重。
   - 确保目标是可达到的，且与个人的健康水平相符。
```